

Rain2FloodNet: 실시간 도시 침수흔적도 예측을 위한 조건부 생성 모델*

서현우⁰¹, 서재민¹, 유재수², 최도진¹

¹국립창원대학교, ²충북대학교

sho5223@naver.com, sksms1802@naver.com, yjs@chungbuk.ac.kr, dojinchoi@changwon.ac.kr

Rain2FloodNet: Conditional Generative Model for Real-Time Urban Flood Footprint Prediction

Hyeon-Woo Seo⁰¹, Jae-Min Seo¹, Jae-Soo Yoo², Do-Jin Choi¹

¹Changwon National University, ²Chungbuk National University

sho5223@naver.com, sksms1802@naver.com, yjs@chungbuk.ac.kr, dojinchoi@changwon.ac.kr

요약

도시침수 피해는 이상기후와 도시화로 인해 빈번히 발생하고 있으나, 기존 물리 기반 예측 모델은 높은 계산 비용과 낮은 실시간성의 한계를 가진다. 이에 본 연구에서는 실제 침수흔적도와 AWS 강수량 데이터를 활용하고, 1, 3, 5시간 최대 강수량의 가중합을 조건 변수로 적용한 Rain2FloodNet 모델을 제안하였다. cGAN과 Rain2FloodNet 모델의 성능을 비교한 결과, 제안하는 구조가 다양한 케이스와 등급별 mIoU 평가에서 cGAN 대비 Best IoU-Grade 기준 약 50배 향상된 침수 등급 예측 성능과 실시간성을 나타냈다.

1. 서론

최근 기상이변과 도시화로 인한 침수 피해가 사회적으로 큰 이슈가 되고 있다. 한국 기상청(2024) 이상기후 보고서[1]에 따르면, 최근 집중호우 및 극심한 기온 변동이 빈번하게 발생하면서 주요 도시에서 다양한 침수 피해가 보고되고 있다. 국가물관리위원회[2] 또한 서울 강남권에서 5차례에 걸쳐 대규모 차량 침수 및 막대한 경제적 피해가 발생했음을 밝힌 바 있다. 이러한 문제에 효과적으로 대응하기 위해서는 다양한 강수 조건과 공간적 특성을 반영할 수 있는 침수 예측 기술이 필수적이다. 전통적으로는 HEC-RAS 등 물리 기반 수치모델이 사용되어 왔으나, 대규모 실시간 예측에서는 높은 계산 비용과 복잡한 입력 요구로 한계가 존재한다. 반면, 최근 딥러닝 기법의 발전은 다양한 입력조건을 빠르게 반영하고 실제 침수 양상을 현실적으로 예측할 수 있는 가능성을 제시하고 있다.

본 연구에서는 실제 지도·침수흔적도[†] 이미지와 자동 기상 관측 장비(Automatic Weather Station, AWS)에서 수집한 1, 3, 5시간 최대 강수량 데이터를 연계하고, 1, 3, 5시간 최대 강수량의 가중합($0.5 \cdot 1h + 0.3 \cdot 3h + 0.2 \cdot 5h$)을 복합 조건으로 설계하여 침수흔적도 예측 모델을 제안한다. 이는 단기 집중호우(1시간)가 침수에 가장 큰 영향을 미치고, 중장기 강수가 침수 심 등에도 영향을 준다는 “랜덤포레스트 회귀모형을 적용한 도

시지역에서의 실시간 침수 예측”[3]의 분석을 바탕으로 결정하였다.

제안하는 모델은 Pix2Pix[4] 구조에 Condition Embed, FiLM(Feature-wise Linear Modulation)[5], Minibatch Discrimination, Condition Regressor 모듈을 추가적으로 적용하여, 강수 조건에 따른 침수흔적도의 변화를 세밀하게 반영할 수 있도록 설계되었다. 또한, 비교 분석을 위해 cGAN(Conditional GAN)[6] 기반의 기본 생성 네트워크도 함께 구현하여, 두 가지 접근 방식의 성능 차이를 다각적으로 분석하였다. 본 연구는 실제 침수 흔적도를 사용하여 침수 예측 가능성을 실증하였다는 점에서 의의가 있다. 또한, 오랜 기간 축적된 데이터에는 도시 침수 저감 사업 등 외부 요인이 반영되어 완벽한 예측이 어렵다는 한계가 있으나, GAN(Generative Adversarial Nets)[7] 기반 모델이 도시 침수 예측 문제에 효과적으로 적용될 수 있음을 실험적으로 입증한다.

2. 전체 모델 구조 및 방법론

2.1 cGAN 기반 모델

[그림 1]은 본 연구의 비교 모델로서, 기본 cGAN 구조를 도입하였다. Generator는 분해번호(공간 ID)의 One-hot 인코딩 벡터, 정규화된 강수량 값, 그리고 랜덤 노이즈 벡터를 입력으로 받아, 다층 Fully Connected(FC)와 Deconvolution(Transpose Convolution) 블록을 순차적으로 통과하여 256×256 크기의 RGB 침수흔적도 이미지를 생성한다. 이 과정에서 분해번호와 강수량 정보가 함께 활용되어, 각 공간·강우 조건에 맞는 침수양상을 모델이 학습할 수 있도록 하였다. Discriminator는 생성된 이미지와 이에 대응하는 조건 벡터를 함께 입력받는다. 이후, 여러 단계의 Convolution, Batch Normalization, Leaky

* 본 연구는 2025년도 과학기술정보통신부 및 정보통신기획평가원의 ‘SW중심대학사업’ 지원을 받아 수행되었음. 본 결과물의 내용을 전제할 수 없으며, 인용(재사용)할 때에는 반드시 과학기술정보통신부와 정보통신기획 평가원이 지원한 ‘SW중심대학’의 결과물이라는 출처를 밝혀야 함(2024-0-00020)

ReLU 활성화, Pooling, 최종적으로 Fully Connected 레이어를 통과하면서 입력 샘플의 진위(Real/Fake)를 판별한다.

학습에는 WGAN-GP(Wasserstein GAN with Gradient Penalty) 손실을 도입하여 판별기의 안정성 및 학습 수렴성을 높였으며, 이미지 복원 정확도를 위한 MAE(Mean Absolute Error, L1 Loss) 손실을 추가적으로 적용하였다. 이러한 손실 조합을 통해, 실제 침수현적도와 유사한 이미지를 생성하는 동시에 다양한 공간·조건 정보를 반영하는 모델 학습을 도모하였다.




그림 1 .cGan 기반 모델

2.2 제안하는 Rain2FloodNet

[그림2]는 본 논문에서 제안하는 Rain2FloodNet 모델을 나타낸다. 제안 모델은 기존 Pix2Pix구조에 Condition Embed, FiLM, Condition Regressor, Minibatch Discrimination 모듈을 추가하여, 다양한 조건 변화에 따른 침수 예측의 정밀성과 학습의 안정성을 동시에 높였다.

먼저, Condition Embed 모듈은 입력 강수량 조건을 고차원 임베딩 벡터로 변환한다. 임베딩 된 벡터는 Generator의 각 인코더 및 디코더 단계에 전달되며, U-Net 구조의 Generator에서는 이 임베딩 벡터를 각 단계의 feature map에 Feature-wise Linear Modulation(FiLM) 방식으로 적용한다. FiLM 구조는 각 단계별로 임베딩된 조건 정보를 채널 단위 scaling(γ)과 shifting(β)을 통해 세밀하게 반영하여 단순 조건 병합(concatenation) 방식보다 다양한 강수 조건 변화에 따른 침수 양상 생성의 정밀도를 한층 높일 수 있다.

Discriminator는 PatchGAN 구조를 기반으로 한다. 입력/타겟 이미지 쌍과 정규화된 강수 조건 벡터를 함께 입력받도록 설계하였다. Minibatch Discrimination(MBD) 모듈을 추가함으로써, 미니배치 내 다양한 생성 결과의 유사성 혹은 차이점을 효과적으로 판별할 수 있게 하였다. 단일 샘플 기반 판별기의 한계를 보완하여, 실제 침수 상황에서 발생하는 다양한 패턴에 대한 판별력을 향상시키기 위함이다. 또한, 생성된 이미지로부터 조건(강수량 값)을 역추정하는 Condition Regressor를 추가적으로 도입하였다. Condition Regression 손실을 통해, 생성 이미지가 실제 입력 조건 정보를 충분히 반영하고 있는지 직접적으로 유도함으로써, 모델의 조건 정보 활용도를 극대화한다. 최종적으로 전체 모델은 WGAN-GP(판별의 안정성), L1(이미지 복원성), Condition Regression(조건 반영성) 손실을 결합하여 학습된다. 제안하는 모델은 조건 변화에 민감한 침수

예측 문제에서 생성 결과의 현실성, 조건 반영의 정확성, 학습의 안정성을 모두 확보하였다.




그림 2 . 제안하는 침수 지도 생성 및 예측 모델
(Rain2FloodNet)

3. 실험 및 결과

실험에는 서울시 강남구의 지도 이미지 및 침수현적도 데이터를 활용하였다. 해당 데이터는 행정안전부 재난보험과에 공식 공문을 통해 요청하여 수신받은 자료로, 침수 전체 기간에 대한 침수현적도와 수심, 면적 등 상세 정보를 포함하고 있다. 제공된 자료는 QGIS 기반의 공간정보 파일과 지도 이미지 형태로 구성되어 있으며, 본 연구의 실시간 침수현적도 생성 모델 학습을 위한 기반 자료로 활용되었다. 각 이미지 데이터는 분해번호(공간 단위) 및 동일 기간의 강수량 CSV 파일과 매칭되었으며, 데이터셋은 분해번호별 강수량 크기에 따라 중앙값(Median), 최소값(Min), 최대값(Max) 조건으로 분류된 Train/Test 세트 구성되었다. 또한 모델의 일반화 성능을 평가하기 위해, 각 분해번호별 0~20mm 범위의 강수 조건을 반영한 흰색 배경 타겟 이미지(white test set)를 추가하였다. 전처리 단계에서는 모든 이미지와 조건 변수를 정규화하여 모델 입력값으로 활용하였다.

3.1 실험 환경 및 평가 지표

본 연구에서는 서울시 강남구 침수현적도 데이터를 대상으로, 학습(train)과 검증(test) 데이터셋을 9:1의 비율로 분할하였으며, 비침수 케이스를 포함하여 모델의 일반화 성능도 함께 평가하였다.

모델 성능 평가는 PSNR(Peak Signal-to-Noise Ratio)[8], SSIM(Structural Similarity Index)[9], mIoU_all(mean Intersection over Union, 전체 mIoU)[10], fg-mIoU(전경 mIoU), 그리고 Iou-Grade(등급별 IoU) 등 다양한 정량적 지표로 수행하였다.

PSNR은 생성 이미지와 참조 이미지 간의 픽셀 차이를 로그 스케일로 나타내어 복원 품질을 평가하며, SSIM은 구조적 특성과 명암, 질감 등 시각적 유사도를 측정한다. mIoU_all은 예측된 침수 영역과 실제 침수 영역 간의 중첩도를 평균적으로 평가하여 전체적인 분할 성능을 나타낸다. fg-mIoU는 전체 이미지 중 실제 침수(전경) 영역을 대상으로 IoU를 산출하여 실질적 예측 성능을 보다 세밀하게 평가한다. Iou-Grade는 침수 등급(Grade 1~6)별로 개별 IoU를 산출하여, 다양한 침수 강도에 대한 예측 정확도를 구체적으로 평가하였다. 본문에서는 가

장 높게 나타난 IoU 값을 Best IoU-Grade로 표기하였다.

3.2 실험 결과 및 분석

모든 실험은 배치 크기 16, 에폭 200, L1 및 Condition Regression 손실 등 다양한 하이퍼파라미터 설정 하에 반복 수행되었으며, 각 모델별로 최고 성능결과를 표 1에 요약하였다.

실험 결과, PSNR과 SSIM과 같은 전역 이미지 품질 평가지표는 두 모델 모두에서 높은 수치를 기록하였다. 이러한 결과는 전체 데이터셋 중 대부분이 침수 영역이 아닌 배경(비침수) 픽셀로 구성되어 있기 때문이며, 실제 침수(전경) 영역의 비율이 매우 작을 뿐만 아니라, 일부 등급(Grade)에서는 실제 침수 발생이 없는 경우도 존재한다는 데이터 특성을 반영한다. mIoU 및 fg-mIoU 등 세분화된 분할 성능 지표는 상대적으로 낮은 값을 보였으나, 이는 실제 현장에서의 침수 예측에서 흔히 마주하는 데이터 불균형 문제를 반영한 결과라 할 수 있다.

실질적인 침수 예측 성능을 평가하기 위해서는 fg-mIoU와 등급별 IoU 등 세밀한 지표가 필수적이다. 표 1에는 각 모델의 평가 지표별 최고 성능을 비교하였다. 실제 침수 데이터의 특성상 등급별 예측 난이도와 데이터 분포가 상이하므로, 각 모델이 침수 영역 중 상대적으로 예측이 용이했던 등급에서 기록한 최대 성능을 참고용으로 제시한 것이다. 제안하는 모델은 Best IoU-Grade에서 cGAN 대비 유의미하게 높은 값을 기록하며, 이는 조건 정보 반영과 침수 영역 분할에서 뚜렷한 개선 효과를 보여준다. 특히, cGAN 모델이 전경 mIoU가 매우 낮아 대부분 배경 위주의 결과를 생성하는 데 그쳤던 반면, 제안하는 모델은 Condition Regression 및 FiLM 구조의 도입을 통해 강수량 조건의 반영력과 등급별 침수 영역 예측 성능 모두에서 실질적인 향상을 달성하였다.

표 1. 성능 평가 결과

Model	Best PSNR	Best SSIM	Best mIoU_all	Best fg-mIoU	Best IoU-Grade
제안하는 모델	25.72	0.9759	0.1518	0.0124	0.1662
cGan	25.80	0.9869	0.1422	0.0003	0.0033

[그림 3]은 생성 이미지 예시를 나타낸다. 생성 이미지는 실제 이미지와 비교해볼 때 시각적으로도 대체로 유사한 경향과 침수 패턴의 재현을 보인다. 아울러, 제안 모델은 GPU 환경 기준 수 초 이내에 침수흔적도 예측 결과를 생성할 수 있어, 실시간 서비스 적용에 있어서도 높은 가능성을 보였다. 이와 같은 결과는 실제 도시 침수 현장에서의 신속한 대응과 의사결정 지원 시스템 구축에도 긍정적인 시사점을 제공한다.



그림 3. 생성이미지 예시

4. 결 론

본 연구에서는 관측 기반 침수흔적도와 다양한 강수 조건을 활용하여, Pix2Pix 구조를 기반으로 조건 임베딩, FiLM, Minibatch Discrimination, Condition Regression 기법을 추가 도입한 Rain2FloodNet 모델을 새롭게 제안하였다. 실험 결과, 제안하는 모델이 전경 및 등급별 mIoU 등 실질적 성능에서 우수함을 확인하였다. 향후에는 더 다양한 침수흔적지도, 조건 변수(지형, 토양, 추가 강수 시간대 등)를 포함한 조건부 생성 모델 구조 연구와 실제 재난 대응 현장 적용을 위한 실시간 예측·시각화 시스템 고도화 연구가 필요하다.

참고문헌

- [1] 한국 기상청, “정부 합동 2024년 이상기후 보고서”, pp. 1-6, 2024.
- [2] 국가물관리 위원회, “2023.5 vol.34:환경이슈”, 2023.
- [3] 김현일, “랜덤포레스트 회귀모형을 적용한 도시지역에서의 실시간 침수 예측”, 한국수자원학회 논문집, Vol. 54, Issue 12s, pp. 1119-1130, 2021.
- [4] Phillip Isola, Jun-Yan Zhu, Tinghui Zhou, Alexei A. Efros, “Image-to-Image Translation with Conditional Adversarial Networks,” Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp.1125-1134, 2017.
- [5] Ethan Perez, Florian Strub, Harm de Vries, Vincent Dumoulin, Aaron Courville, “FiLM: Visual Reasoning with a General Conditioning Layer,” AAAI Conference on Artificial Intelligence, pp.3942-3951, 2018.
- [6] Mehdi Mirza, Simon Osindero, “Conditional Generative Adversarial Nets,” arXiv preprint arXiv:1411.1784, 2014.
- [7] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, Yoshua Bengio, “Generative Adversarial Nets,” Advances in Neural Information Processing Systems, vol. 27, pp. 2672-2680, 2014.
- [8] Huynh-Thu, Q., & Ghanbari, M., “Scope of validity of PSNR in image/video quality assessment,” Electronics Letters, vol. 44, no. 13, pp. 800-801, 2008.
- [9] Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P., “Image quality assessment: from error visibility to structural similarity,” IEEE Transactions on Image Processing, vol. 13, no. 4, pp. 600-612, 2004.
- [10] Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., & Zisserman, A. “The PASCAL Visual Object Classes (VOC) Challenge,” International Journal of Computer Vision (IJCV), Vol. 88, No. 2, pp. 303-338, 2010.